

Reverse Stress Testing du risque géopolitique en crédit corporate

Document 20/20 : prérequis + résumé ultra complet + méthodologie Python (exposition & secteur)

Diallo Mamadou Cherif

6 mars 2026

Table des matières

1	Résumé exécutif (à dire en 45 secondes)	3
2	Glossaire des symboles (zéro ambiguïté)	3
3	Prérequis techniques (checklist exhaustive + mini-exemples)	4
3.1	A. Concepts crédit (EAD, PD, LGD) – pièges	4
3.2	B. CET1, RWA, seuils de rupture (Pillar 1, buffers)	4
3.3	C. Probabilités : normale multivariée, ellipses, Mahalanobis, p-value	4
3.4	D. Modèle de dépendance des défauts (ASRF/IRB) : facteur latent	4
3.5	E. Optimisation sous contrainte : convexité, non-convexité, optima locaux	4
3.6	F. Copules et vine copulas (mention du papier) – intuition	4
4	Résumé ultra complet du papier (structure + équations + interprétation)	5
4.1	1. Motivation et contexte prudentiel (ECB/BCBS)	5
4.2	2. Littérature : reverse stress test quantitatif et ses limites	5
4.2.1	2.1 Approches existantes (principalement market risk)	5
4.2.2	2.2 Forward vs reverse en crédit bancaire	5
4.3	3. Espace des scénarios, risque géopolitique, cadre capital	5
4.3.1	3.1 Portefeuille et seuil de rupture	5
4.3.2	3.2 Vecteur de scénario et distribution de référence	6
4.4	4. Pertes de portefeuille et capital sous stress géopolitique	6
4.4.1	4.1 Cartographier (g, x) vers la distribution de perte	6
4.4.2	4.2 Capital CET1 et RWA sous stress	7
4.5	5. Reverse stress test : design point + familles de scénarios	8
4.5.1	5.1 Design point : optimisation sous contrainte	8
4.5.2	5.1 bis Hypothèse gaussienne : Mahalanobis (géométrie transparente)	8
4.5.3	5.2 Scénarios plausibles multiples (gouvernance)	8
4.5.4	5.3 Interprétation économique du design point (secteurs, PD/LGD)	9
5	6. Mise en œuvre opérationnelle (fidèle au papier) + version “Python-ready”	10
5.1	6.1 Étapes de mise en œuvre (Figure roadmap)	10
5.2	6.2 Mesure du risque géopolitique (GPR : Threats vs Acts)	10
5.3	6.3 Implémentation numérique : lissage, whitening, multi-start	10
5.3.1	(i) Lissage (saturation lisse vs troncature dure)	10
5.3.2	(ii) Whitening (coordonnées blanchies)	10
5.3.3	(iii) Non-convexité : multi-start	10
5.4	6.4 D’un ensemble infini à une liste finie (gouvernance-ready)	11

5.4.1	Étape 1 : construire un pool $\mathcal{C}_N$ dans E	11
5.4.2	Étape 2 : réduire à P scénarios non redondants (maximin)	11
5.4.3	Étape 3 : reporter sévérité, plausibilité, drivers	11
6	Plan 20/20 : méthodologie Python ultra détaillée (exposition + secteur)	12
6.1	A. Données attendues (deux granularités)	12
6.2	B. Pipeline complet (fidèle sections 6.1–6.4)	12
6.3	C. Arborescence projet (reproductible)	13
6.4	D. Snippets Python (les briques clés)	13
7	Plan d’expérience / validation (pour “20/20”)	15
7.1	1) Tests data & plausibilité	15
7.2	2) Diagnostics optimisation	15
7.3	3) Gouvernance multi-scénarios	15
7.4	4) Backtesting narratif	15
8	Schémas (TikZ) : compréhension visuelle	16
8.1	Figure conceptuelle : ellipses de plausibilité et frontière de rupture	16
8.2	Roadmap 4 étapes	16
A	Annexe A.1 : Référence Student multivariée (heavy tails) – du papier	16
B	Annexe A.2 : Version sectorielle (équations 56–62 du papier) + explication	17
C	Références (sélection minimale, à compléter si besoin)	17

1 Résumé exécutif (à dire en 45 secondes)

Problème : un stress test classique (*forward*) impose un scénario macro-financier, puis calcule les pertes et le ratio de capital. Ici, on fait l'inverse : on fixe **un état de rupture** (ex. déplétion de 300 bps du ratio CET1) et on cherche **le scénario géopolitique + macro-financier le plus plausible** qui provoque cette rupture.

Cadre : on définit un scénario $s = (g, x)$ où g mesure un choc géopolitique (index exogène type GPR) et x regroupe des chocs macro-financiers (activité, taux, spreads, commodities, etc.). On construit une **distribution de référence** $P_S(\cdot \mid I)$ (souvent gaussienne) sur ces chocs. On cartographie ensuite :

$$(g, x) \rightarrow (\text{PD}_i(g, x), \text{LGD}_i(g, x)) \rightarrow L_q(g, x) \rightarrow \text{CET11}(g, x), \text{RWA}(g, x) \rightarrow R(s).$$

Le reverse stress test devient une optimisation : **minimiser la distance de Mahalanobis** (donc maximiser la plausibilité) **sous la contrainte** $R(s) \leq R$ et $g > 0$.

Gouvernance : au-delà d'un point unique s (design point), le papier construit des ensembles de scénarios plausibles (S_η local et N_ε quasi-optimal) et propose une procédure en 3 étapes pour produire une **liste courte** de scénarios **diversifiés, auditable** : générer un grand pool $\mathcal{C}_N$ (ancres + exploration locale), réduire par règle maximin (farthest-point) à $\mathcal{C}_P$, puis reporter sévérité/plausibilité/drivers en coordonnées blanchies.

2 Glossaire des symboles (zéro ambiguïté)

Symbole	Définition / interprétation
$s = (g, x)^\top \in \mathbb{R}^d$	Vecteur scénario : g choc géopolitique, $x \in \mathbb{R}^{d-1}$ chocs macro-financiers.
$S = (G, X)^\top$	Variable aléatoire des scénarios (loi de référence).
I	Information disponible à l'origine du test (date $t = 0$).
Σ	Covariance des chocs (G, X) (référence), SPD.
L	Cholesky : $\Sigma = LL^\top$.
$y = L^{-1}s$	Coordonnées blanchies (whitened).
$d_\Sigma^2(s)$	Mahalanobis au carré : $s^\top \Sigma^{-1} s$.
$\pi(s)$	Score de plausibilité type p-value : $\mathbb{P}(d_\Sigma^2(S) \geq d_\Sigma^2(s))$.
$i = 1, \dots, n$	Index expositions (emprunteurs/positions).
$k = 1, \dots, K$	Index secteurs ; $k(i)$ secteur de l'exposition i .
EAD_i	Exposure at Default : exposition brute au défaut.
$\text{PD}_i^0, \text{LGD}_i^0$	Paramètres baseline (non stressés) horizon h .
$\text{PD}_i(g, x), \text{LGD}_i(g, x)$	Paramètres stressés sous scénario.
ρ_i	Corrélation d'actif (ASRF/IRB) ; parfois notée ζ .
Z, ε_i	Facteur systématique et idiosyncratique (normaux).
D_i	Indicateur de défaut $\in \{0, 1\}$.
$L(g, x)$	Perte totale ; $L_q(g, x)$ quantile de perte (queue) niveau q .
$\text{CET11}_0, \text{RWA}_0$	Capital CET1 et RWA initiaux.
R_0	Ratio initial $R_0 = \text{CET11}_0/\text{RWA}_0$.
R	Seuil de rupture ; rupture si $R(s) \leq R$.
$s^=(g^x)$	Design point : scénario cassant le plus plausible.
S_{red}	Ensemble cassant : $\{s : R(s) \leq R\}$.
S_η	Voisinage local cassant autour de s .
N_ε	Ensemble quasi-optimal (cassant et presque aussi plausible que s).
$\mathcal{C}_N$	Pool de candidats admissibles.
$\mathcal{C}_P$	Liste courte (5–12 scénarios).

3 Prérequis techniques (checklist exhaustive + mini-exemples)

3.1 A. Concepts crédit (EAD, PD, LGD) – pièges

- EAD : exposition au défaut (principal + intérêts + tirages attendus). *Ce n'est pas la perte.*
- LGD : % perdu *conditionnellement au défaut*. Elle résume recouvrement, collatéral, coûts de workout.
- **Perte si défaut** : $Perte \approx EAD \times LGD$. Donc oui, LGD “s’applique” à EAD.
- **Piège** : dire “EAD inclut le collatéral” $\Rightarrow$ non ; le collatéral agit via LGD (recouvrement), pas via EAD.

3.2 B. CET1, RWA, seuils de rupture (Pillar 1, buffers)

Le papier propose deux ancrages :

- **Déplétion relative** : $R = R_0(1 - \Delta)$, typiquement $\Delta = 0.03$ pour 300 bps.
- **Ancrage réglementaire** : $R =$ minimum CET1 Pillar 1 (4.5%) + buffers (conservation, etc.).

Piège exam : ne pas confondre “baisse de 300 bps” avec “300%”. 300 bps = 3 points de pourcentage.

3.3 C. Probabilités : normale multivariée, ellipses, Mahalanobis, p-value

Si $S \sim \mathcal{N}(0, \Sigma)$, alors la densité s’écrit :

$$f(s) \propto \exp\left(-\frac{1}{2}s^\top \Sigma^{-1}s\right) = \exp\left(-\frac{1}{2}d_\Sigma^2(s)\right).$$

Les ensembles $\{d_\Sigma^2(s) = c\}$ sont des **courbes d’iso-densité** : en 2D, ce sont des **ellipses**.

- **Même densité** $\neq$ “même probabilité pour chaque point” (un point a probabilité 0).
- **Interprétation correcte** : “sur la ligne de l’ellipse, la densité est constante”.

Sous gaussien : $d_\Sigma^2(S) \sim \chi_d^2$. On définit un score de plausibilité :

$$\pi(s) = \mathbb{P}(d_\Sigma^2(S) \geq d_\Sigma^2(s)) = 1 - F_{\chi_d^2}(d_\Sigma^2(s)).$$

Piège : pourquoi $1 - F$? parce que $F(u) = \mathbb{P}(d_\Sigma^2(S) \leq u)$ et on veut “au moins aussi extrême”.

3.4 D. Modèle de dépendance des défauts (ASRF/IRB) : facteur latent

Le papier utilise une structure 1-facteur :

$$Y_i = \sqrt{\rho_i} Z + \sqrt{1 - \rho_i} \varepsilon_i,$$

avec $Z \sim \mathcal{N}(0, 1)$ commun et $\varepsilon_i \sim \mathcal{N}(0, 1)$ idiosyncratique, indépendants.

- **Pourquoi ?** créer une corrélation des défauts : si Z chute, beaucoup de Y_i chutent ensemble $\Rightarrow$ pertes extrêmes.
- **Piège** : confondre “facteur latent” avec “variable observée”. Ici Z est un mécanisme de dépendance, pas un facteur macro observé.

3.5 E. Optimisation sous contrainte : convexité, non-convexité, optima locaux

- **Convexe** : une solution globale stable ; **non-convexe** : plusieurs minima locaux $\Rightarrow$ multi-start.
- **Contrainte saturée** : à l’optimum, typiquement $R(s) = R$. Si $R(s) < R$, on peut réduire l’amplitude du choc et gagner en plausibilité.

3.6 F. Copules et vine copulas (mention du papier) – intuition

Une **copule** assemble des marginales (distribution de G , de X_1 , etc.) en une dépendance conjointe. Une **vine copula** construit une grande dimension via copules bivariées organisées en arbres. **Message du papier** : très flexible (dépendance non linéaire, dépendance de queue, multimodalité) mais plus lourd à calibrer, donc parfois moins “gouvernance-ready”.

4 Résumé ultra complet du papier (structure + équations + interprétation)

4.1 1. Motivation et contexte prudentiel (ECB/BCBS)

Le papier part d'un fait : la supervision insiste depuis longtemps sur le reverse stress testing, mais la formalisation quantitative et surtout l'intégration du risque géopolitique dans un cadre *crédit + capital réglementaire* restent rares.

Le superviseur (ECB) annonce un exercice demandant une déplétion d'au moins 300 bps de CET1, et l'objectif est **gouvernance** (dialogue prudentiel, gouvernance, plan de contingence) plus que "calcul mécanique d'exigences de capital".

4.2 2. Littérature : reverse stress test quantitatif et ses limites

4.2.1 2.1 Approches existantes (principalement market risk)

Le reverse stress test quantitatif est souvent formulé comme :

- un mode conditionnel : scénario le plus probable conditionnellement à "perte extrême" ;
- un problème d'optimisation sous contraintes (Glasserman, Kopeliovich) ;
- extensions heavy-tail / skew-elliptique ;
- vraisemblance empirique : "tilt" la loi de référence pour satisfaire une contrainte de perte ;
- robustesse distributionnelle : divergence (Pesenti) ;
- copules/vines pour dépendances riches.

Limite clé : ces cadres sont souvent pensés pour des portefeuilles de marché et des seuils de pertes type VaR/ES, et *abstraient* des mécaniques PD/LGD, dépendance des défauts et capital réglementaire.

4.2.2 2.2 Forward vs reverse en crédit bancaire

Forward (orienté vers l'avant) : on donne un scénario macro, puis on propage vers PD/LGD, pertes et ratio de capital. **Reverse (inverse)** : on fixe d'abord un état de rupture (ex. $R \leq R$), puis on cherche le scénario (g, x) le plus plausible qui produit cette rupture.

4.3 3. Espace des scénarios, risque géopolitique, cadre capital

4.3.1 3.1 Portefeuille et seuil de rupture

Portefeuille corporate avec expositions $i = 1, \dots, n$. Total :

$$\text{EAD} = \sum_{i=1}^n \text{EAD}_i. \quad (1)$$

Capital et RWA initiaux CET1_0 , RWA_0 ; ratio initial :

$$R_0 = \frac{\text{CET1}_0}{\text{RWA}_0}. \quad (2)$$

Seuil R , avec $0 < R < R_0$. Choix recommandé pour 300 bps :

$$R = R_0(1 - \Delta), \quad \Delta = 0.03. (4)$$

Alternative : $R = \text{Pillar 1 (4.5\%)} + \text{buffers}$.

4.3.2 3.2 Vecteur de scénario et distribution de référence

Le scénario est :

$$s = \begin{pmatrix} g \\ x \end{pmatrix} \in \mathcal{S}, \quad x \in \mathbb{R}^{d-1}, \quad g \in \mathbb{R}. \quad (5)$$

Interprétation :

- g : intensité du stress géopolitique, normalisée avec $g = 0$ baseline.
- x : chocs macro-financiers (activité réelle, taux, spreads, matières premières, demande sectorielle, etc.).

La loi de référence $P_S(\cdot | I)$ peut être :

- paramétrique (gaussienne, Student-t),
- copule liant marginales de G et X ,
- modèle multivarié conditionnel (VAR, espace d'états),
- changements de régime.

Le papier garde volontairement cette brique générale : **le reverse stress n'impose pas une seule famille** ; il exige juste une notion cohérente de plausibilité.

4.4 4. Pertes de portefeuille et capital sous stress géopolitique

4.4.1 4.1 Cartographeur (g, x) vers la distribution de perte

Étape 1 : scénarios $\rightarrow$ PD.

$$PD_i(s) = PD_i(g, x) = f_i(g, x), \quad (6)$$

avec contrainte $PD_i \in (0, 1)$. Forme parcimonieuse par secteur $k(i)$:

$$\log \frac{PD_i(g, x)}{1 - PD_i(g, x)} = \log \frac{PD_i^0}{1 - PD_i^0} + \beta_{k(i)}^\top x + \delta_{k(i)} g. \quad (7)$$

Solution fermée :

$$PD_i(g, x) = \frac{PD_i^0 \exp(\beta_{k(i)}^\top x + \delta_{k(i)} g)}{1 - PD_i^0 + PD_i^0 \exp(\beta_{k(i)}^\top x + \delta_{k(i)} g)}. \quad (8)$$

Interprétation : $\delta_k > 0$ si le risque géopolitique augmente les défauts (secteurs exposés commerce mondial, sanctions, supply-chain). Le papier note qu'on peut imposer des contraintes de signe en stress.

Étape 2 : scénarios $\rightarrow$ LGD.

$$LGD_i(s) = LGD_i(g, x) = g_i(g, x), \quad (9)$$

avec $LGD \in (0, 1)$. Spécification affine fréquente :

$$LGD_i(g, x) = LGD_i^0 + \gamma_{k(i)}^\top x + \eta_{k(i)} g. \quad (10)$$

Interprétation : η_k capture l'impact géopolitique sur recouvrements (saisies, exécution transfrontalière, valeur collatéral, restrictions de vente d'actifs gagés).

Étape 3 : dépendance des défauts (facteur latent).

$$Y_i = \sqrt{\rho_i} Z + \sqrt{1 - \rho_i} \varepsilon_i, \quad (11)$$

défaut si :

$$Y_i \leq \Phi^{-1}(PD_i(g, x)), \quad (12)$$

indicateur :

$$D_i(g, x) = \mathbf{1}\{Y_i \leq \Phi^{-1}(\text{PD}_i(g, x))\}. \quad (13)$$

Perte conditionnelle exposition :

$$L_i(g, x) = \text{EAD}_i \text{LGD}_i(g, x) D_i(g, x), \quad (14)$$

perte totale :

$$L(g, x) = \sum_{i=1}^n L_i(g, x). \quad (15)$$

Étape 4 : pertes extrêmes (queue) via approximation analytique. Pour un niveau de confiance q (ex. 99.9%) :

$$L_q(g, x) \approx \sum_{i=1}^n \text{EAD}_i \text{LGD}_i(g, x) \Phi\left(\frac{\Phi^{-1}(\text{PD}_i(g, x)) + \sqrt{\rho_i} \Phi^{-1}(q)}{\sqrt{1 - \rho_i}}\right). \quad (16)$$

Lecture : cette formule donne une **perte de queue** (type VaR crédit) en agrégeant les contributions, en tenant compte de la corrélation d'actif via ρ_i et du quantile q via $\Phi^{-1}(q)$.

4.4.2 4.2 Capital CET1 et RWA sous stress

CET1 sous stress.

$$\text{CET11}(g, x) = \text{CET11}_0 - L_q(g, x) + \Delta P \& L_{\text{non credit}}(g, x). \quad (17)$$

Note : dans une analyse “pur crédit”, on peut fixer $\Delta P \& L_{\text{non credit}} = 0$ ou le modéliser simplement (linéaire) si on veut capturer trading/fees/opex.

RWA sous stress. Le poids de risque de l'exposition i :

$$RW_i(g, x) = h(\text{PD}_i(g, x), \text{LGD}_i(g, x), M_i), \quad (18)$$

et la fonction IRB (forme du papier) :

$$h(\text{PD}, \text{LGD}, M) = \text{LGD} \left[\Phi\left(\frac{\Phi^{-1}(\text{PD}) + \sqrt{\rho} \Phi^{-1}(q)}{\sqrt{1 - \rho}}\right) - \text{PD} \right] \times \varpi(M), \quad (19)$$

où $\varpi(M)$ est l'ajustement de maturité. Total :

$$\text{RWA}(g, x) = \sum_{i=1}^n \text{EAD}_i RW_i(g, x). \quad (20)$$

Approximation linéaire possible :

$$\text{RWA}(g, x) = \text{RWA}_0 + \sum_{i=1}^n \alpha_i (\text{PD}_i(g, x) - \text{PD}_i^0), \quad (21)$$

avec α_i calibrés sur sorties modèle interne et historique.

Ratio CET1.

$$R(s) = \frac{\text{CET11}(g, x)}{\text{RWA}(g, x)}. \quad (22)$$

Rupture si :

$$R(s) \leq R^{(23)}$$

4.5 5. Reverse stress test : design point + familles de scénarios

4.5.1 5.1 Design point : optimisation sous contrainte

Le reverse stress point (design point) est :

$$s \in \arg \max_{s \in \mathcal{S}} f(s|I) \quad \text{s.c.} \quad R(s) \leq R^*, \quad g > 0. \quad (24)$$

On définit la zone cassante (zone rouge) :

$$S_{\text{red}} = \{s \in \mathcal{S} : R(s) \leq R^*\} \quad (25)$$

On peut ajouter des contraintes de faisabilité :

$$g_{\min} \leq g \leq g_{\max}, \quad x_{\min} \leq x \leq x_{\max}, \quad (26)$$

et des contraintes de monotonie (stress-only) :

$$PD_i(s) \geq PD_i^0, \quad LGD_i(s) \geq LGD_i^0, \quad i = 1, \dots, n. \quad (27)$$

Pourquoi la contrainte est saturée à l'optimum (le “alpha” qui t’a bloqué). Idée : si $R(s) < R^*$, tu casses “trop”. En général, en réduisant l’intensité du scénario (scaling) tu augmentes sa plausibilité tout en restant cassant. Donc l’optimum ne peut pas être strictement à l’intérieur. Conclusion (sous conditions de régularité) :

$$s \in \partial S_{\text{red}} = \{s \in \mathcal{S} : R(s) = R^*\} \quad (28)$$

Interprétation simple : le scénario optimal est celui qui *casse juste* (au seuil), et parmi ceux-là, il choisit le plus plausible.

4.5.2 5.1 bis Hypothèse gaussienne : Mahalanobis (géométrie transparente)

On suppose :

$$S \sim \mathcal{N}(0, \Sigma). \quad (29)$$

Comme :

$$f(s | I) \propto \exp\left(-\frac{1}{2} s^\top \Sigma^{-1} s\right), \quad (30)$$

maximiser f revient à minimiser la forme quadratique :

$$s \in \arg \min_{s \in S_{\text{red}}, g > 0} \frac{1}{2} d_\Sigma^2(s). \quad (31)$$

Sous normalité :

$$d_\Sigma^2(S) \sim \chi_d^2, \quad (32)$$

et un score de plausibilité (queue) :

$$\mathbb{P}(d_\Sigma^2(S) \geq d_\Sigma^2(s)) = 1 - F_{\chi_d^2}(d_\Sigma^2(s)). \quad (33)$$

Mini-exemple chiffré : si $d = 2$ et $d_\Sigma^2(s) = 6$, alors $\pi(s)^{=1-F_{\chi_2^2}(6)}$ = probabilité d’observer un choc conjoint au moins aussi extrême.

4.5.3 5.2 Scénarios plausibles multiples (gouvernance)

Un point unique est utile mais insuffisant : la gouvernance veut une gamme de scénarios.

Voisinage local S_η (perturbations autour de s). On définit une distance $\delta(s, t)$ et une boule :

$$B_\eta(s) = \{s \in \mathcal{S} : \delta(s, s) \leq \eta\}, \quad (34)$$

puis :

$$S_\eta = S_{\text{red}} \cap B_\eta(s). \quad (35)$$

Sous gaussien, une distance naturelle est Mahalanobis sur l'écart :

$$S_\eta = S_{\text{red}} \cap \{s : d_\Sigma^2(s - s) \leq \eta\}. \quad (36)$$

Intuition : sensibilité locale : “si je bouge légèrement le scénario, est-ce que je casse encore?”.

Ensemble quasi-optimal N_ε (alternatives lointaines mais plausibles). Définition :

$$N_\varepsilon := \{s \in \mathcal{S} : R(s) \leq R, g > 0, -\log f(s|I) \leq -\log f(s^{(I)} + \varepsilon/2)\}. \quad (37)$$

Pourquoi le $+\varepsilon/2$ et le signe $\leq$?

- $-\log f$ est une **pénalité** (plus petit = plus plausible).
- On autorise des scénarios dont la pénalité est **au plus** $\varepsilon/2$ au-dessus de l'optimum.
- Donc on écrit $-\log f(s) \leq -\log f(s)^{+\varepsilon/2}$.

Sous normalité, $-\log f(s)$ est proportionnel à $\frac{1}{2}d_\Sigma^2(s)$, donc :

$$N_\varepsilon = \{s : R(s) \leq R, g > 0, d_\Sigma^2(s) \leq d_\Sigma^2(s) + \varepsilon\}. \quad (38)$$

Lecture : on prend tous les scénarios cassants situés entre deux ellipses : l'ellipse de s et une ellipse légèrement plus grande.

4.5.4 5.3 Interprétation économique du design point (secteurs, PD/LGD)

En évaluant les mappings au point $s^{(g, x)}$:

$$\text{PD}_i = \text{PD}_i(g, x), \quad \text{LGD}_i = \text{LGD}_i(g, x), \quad i = 1, \dots, n. \quad (40)$$

Quantile et ratio :

$$L_q = L_q(g, x), \quad R(g, x) = R. \quad (41)$$

Interprétation : g est la coordonnée géopolitique minimale plausible qui amène le portefeuille à la frontière; x est le *compagnon macro* le plus plausible conditionnellement à g (dépendance conjointe via P_S). **Ce n'est pas un worst-case**, c'est le **plus crédible** qui casse.

Agrégation sectorielle (diagnostic). Poids intra-secteur :

$$\omega_{i|k} = \frac{\text{EAD}_i}{\sum_{j:k(j)=k} \text{EAD}_j}, \quad i : k(i) = k. \quad (42)$$

PD/LGD sectoriels :

$$\text{PD}_k(g, x) = \sum_{i:k(i)=k} \omega_{i|k} \text{PD}_i(g, x), \quad \text{LGD}_k(g, x) = \sum_{i:k(i)=k} \omega_{i|k} \text{LGD}_i(g, x). \quad (43)$$

Au design point :

$$\text{PD}_k = \text{PD}_k(g, x), \quad \text{LGD}_k = \text{LGD}_k(g, x), \quad k = 1, \dots, K. \quad (44)$$

Ce que ça sert : savoir si la rupture vient surtout de (i) PD (plus de défauts), (ii) LGD (pertes plus sévères), ou (iii) les deux, et dans quels secteurs.

Pour tout scénario $s \in S_\eta$ ou $s \in N_\varepsilon$, on peut reporter :

$$\text{PD}_i(g, x), \text{LGD}_i(g, x), L_q(g, x), R(g, x), d_\Sigma^2(s). \quad (45)$$

5 6. Mise en œuvre opérationnelle (fidèle au papier) + version “Python-ready”

5.1 6.1 Étapes de mise en œuvre (Figure roadmap)

Le papier structure l’opérationnel en 4 étapes :

1. Choisir g (proxy géopolitique) et x (facteurs macro), estimer Σ sur historique (ajuster si ruptures/régimes).
2. Calibrer les cartographies $(g, x) \rightarrow \text{PD}$ et $(g, x) \rightarrow \text{LGD}$ (exposition ou secteur).
3. Spécifier les briques capital : dépendance des défauts, agrégation de portefeuille, RWA (fonction IRB ou approximation).
4. Résoudre numériquement l’optimisation sous contraintes $\rightarrow s$, et si besoin S_η et N_ε .

5.2 6.2 Mesure du risque géopolitique (GPR : Threats vs Acts)

Le papier propose comme proxy principal l’indice GPR (Caldara & Iacoviello) :

- construit à partir de la fréquence d’articles de presse relatant tensions, guerres, conflits, terrorisme ;
- décomposé en **Threats** (menaces) et **Acts** (actes) : important car menaces affectent primes/conditions de crédit sans conflit réalisé, tandis que actes déclenchent des ajustements abrupts/non-linéaires ;
- deux propriétés : **exogénéité** (indépendant des variables macro domestiques) et **long historique**.

Le cadre est agnostique : indices alternatifs possibles si exogènes et intégrables dans P_S .

5.3 6.3 Implémentation numérique : lissage, whitening, multi-start

5.3.1 (i) Lissage (saturation lisse vs troncature dure)

Problème : si on impose $\text{PD} \in (0, 1)$ et $\text{LGD} \in (0, 1)$ via `clip`, on crée des **coudes** qui gênent les solveurs SQP. Solution : remplacer par transformations lisses :

- **Sigmoïde** : $u \mapsto \frac{1}{1+e^{-u}}$ pour projeter dans $(0, 1)$,
- **Softplus** : $u \mapsto \log(1 + e^u)$ pour imposer $g \geq 0$.

5.3.2 (ii) Whitening (coordonnées blanchies)

Cholesky $\Sigma = LL^\top$ et changement de variable :

$$y = L^{-1}s, \quad s = Ly.$$

Alors :

$$\frac{1}{2}d_\Sigma^2(s) = \frac{1}{2}s^\top \Sigma^{-1}s = \frac{1}{2}\|y\|_2^2.$$

Donc les ellipses deviennent des sphères en y -space, et les distances (y compris diversité) se calculent en $\|\cdot\|_2$.

5.3.3 (iii) Non-convexité : multi-start

Si S_{red} est non convexe ou $R(\cdot)$ très non linéaire, plusieurs optima locaux existent. Le papier recommande :

- multi-start en y -space : y_0 tiré aléatoirement ou grilles,
- grilles grossières sur g + optimisation conditionnelle sur x ,
- retenir la solution faisable avec plus petite $d_\Sigma^2(\cdot)$.

5.4 6.4 D'un ensemble infini à une liste finie (gouvernance-ready)

On note l'ensemble cible :

$$E \in \{S_\eta, N_\varepsilon\}, \quad E \subseteq S_{\text{red}} = \{s : R(s) \leq R\} \quad (46)$$

5.4.1 Étape 1 : construire un pool $\mathcal{C}_N$ dans E

Objectif : couvrir plusieurs narratifs si non-convexité, puis densifier localement.

Exploration globale via ancres (multi-start + déduplication). On résout le problème ponctuel depuis plusieurs initialisations ; on conserve les solutions faisables distinctes (déduplication par distance en y). Ces ancres ne sont pas reportées directement : elles servent de “squelette” narratif.

Ancres via *intensity ladder* géopolitique. Comités raisonnent en intensité (mild/moderate/severe). On prend une grille $\{g_j\}$ et on calcule :

$$x^{(g_j)} \in \arg \min_x \frac{1}{2} d_\Sigma^2((g_j, x)) \quad \text{s.c.} \quad R(g_j, x) \leq R \quad (47)$$

Interprétation : *conditionnellement à l'intensité géopolitique g_j , le macro $x^{(g_j)}$ est le compagnon le plus plausible qui casse encore.* Si $E = N_\varepsilon$, on conserve seulement les ancres qui respectent aussi $d_\Sigma^2((g_j, x^{(g_j)})) \leq d_\Sigma^2(s) + \varepsilon$.

Exploration locale autour des ancres. Pour chaque ancre s^{anc} , on passe en $y^{anc} = L^{-1}s^{anc}$. On tire une direction u uniformément sur la sphère unité et un rayon r dans un intervalle compact :

$$y = y^{anc} + ru, \quad s = Ly. \quad (48)$$

On accepte s si $s \in S_{\text{red}}$ et $s \in E$:

- si $E = S_\eta$: accepter si $d_\Sigma^2(s - s) \leq \eta$;
- si $E = N_\varepsilon$ (gaussien) : accepter si $d_\Sigma^2(s) \leq d_\Sigma^2(s) + \varepsilon$;
- modèles elliptiques : remplacer $d_\Sigma^2(\cdot)$ par un score monotone $\pi(\cdot)$.

Si le taux d'acceptation est faible (région fine/incurvée), utiliser une marche aléatoire contrainte (hit-and-run / slice) qui ne demande qu'un oracle d'appartenance (oui/non), pas de dérivées.

5.4.2 Étape 2 : réduire à P scénarios non redondants (maximin)

On note $y^{(i)} = L^{-1}s^{(i)}$ le pool en y -space. On initialise $s^{[1]} = s$ puis :

$$s^{[p]} \in \arg \max_{s \in \mathcal{C}_N \setminus \{s^{[1]}, \dots, s^{[p-1]}\}} \min_{\ell \in \{1, \dots, p-1\}} \|L^{-1}(s - s^{[\ell]})\|_2, \quad p = 2, \dots, P. \quad (49)$$

Compréhension simple : à chaque ajout, on prend le point qui augmente le plus la *couverture* (distance au plus proche déjà sélectionné maximale). Ce n'est pas “le plus loin du dernier point”.

5.4.3 Étape 3 : reporter sévérité, plausibilité, drivers

Pour chaque scénario $s^{[p]}$:

- Sévérité : $R(s^{[p]})$ (et éventuellement décomposition via L_q , ΔRWA).
- Plausibilité : $d_\Sigma^2(s^{[p]})$ et score de queue $\pi(s^{[p]})$.
- Drivers : $y^{[p]} = L^{-1}s^{[p]}$; lister les coordonnées avec plus grandes valeurs absolues (et leurs signes).

6 Plan 20/20 : méthodologie Python ultra détaillée (exposition + secteur)

6.1 A. Données attendues (deux granularités)

Voie A (exposition-level)

Table expositions (une ligne par i) :

$$(\text{EAD}_i, \text{PD}_i^0, \text{LGD}_i^0, \rho_i, M_i, \text{secteur } k(i), \dots)$$

Table drivers temporelle (une ligne par date) :

$$(g_t, x_t), \quad x_t \in \mathbb{R}^{d-1}.$$

Option : séries de défauts/charge-off/delinquency pour calibrer sensibilités.

Voie B (sector-level)

Pour chaque secteur k :

$$(\text{EAD}_k, \text{PD}_k^0, \text{LGD}_k^0, \rho_k, \text{sensibilités } b_k, d_k, c_k, e_k).$$

6.2 B. Pipeline complet (fidèle sections 6.1–6.4)

Étape 1 : construire chocs et estimer Σ .

1. Mettre en fréquence commune (trimestriel conseillé).
2. Transformer en chocs : Δ ou $\Delta \log$ selon variable.
3. Standardiser (z-score) : baseline 0 et écart-type 1.
4. Estimer $\Sigma = \text{Cov}(s)$; shrinkage Ledoit-Wolf (robustesse) recommandé.
5. Calculer L (Cholesky) et stocker un `sigma_report.md` (corrélations, eigenvalues, condition number).

Étape 2 : calibrer $(g, x) \rightarrow \text{PD}$ et $(g, x) \rightarrow \text{LGD}$.

- **Voie A** : estimer β_k, δ_k via régression sur $\text{logit}(\text{PD})$; estimer γ_k, η_k via régression LGD ; imposer signes si stress-only ; régulariser (ridge) si besoin.
- **Voie B** : calibrer directement b_k, d_k, c_k, e_k sur agrégats secteur (Annexe A.2).

Étape 3 : construire $R(s)$ (bloc capital). Implémenter les fonctions :

$$s \mapsto \text{PD}(s), \text{LGD}(s) \mapsto L_q(s) \mapsto \text{CET11}(s), \text{RWA}(s) \mapsto R(s).$$

Décider : RWA IRB (19) ou approximation (21). En MVP, (21) est plus simple et auditable.

Étape 4 : résoudre le design point s . Travailler en y -space :

$$\min \frac{1}{2} \|y\|^2 \quad \text{s.c.} \quad R(Ly) \leq R^*, \quad g(Ly) > 0, \quad \text{bornes.}$$

Multi-start (≈ 10) + diagnostics (feasibility $|R(s) - R^*|$, $d_\Sigma^2(s)$, p-value).

Étape 5 : construire S_η et/ou N_ε . Choisir η et ε (gouvernance). Construire tests d'appartenance (oracle oui/non).

Étape 6 : scénarios finis (6.4).

1. Pool $\mathcal{C}_N$: ancres multi-start + intensity ladder + exploration locale (48); éventuellement hit-and-run.
2. Réduction maximin (49) à $\mathcal{C}_P$; $P = 5-12$.
3. Reporting : sévérité, plausibilité, drivers (top- k $|y_j|$).

6.3 C. Arborescence projet (reproductible)

```
rst_geo_credit/  
  README.md  
  requirements.txt  
  config.yaml  
  run_all.py  
  data/raw/{exposures.csv, drivers.csv}  
  src/  
    io_data.py  
    shocks.py  
    sigma.py  
    calib_pd_lgd.py  
    asrf_losses.py  
    capital_rwa.py  
    objective_constraints.py  
    optimise_design_point.py  
    anchors_pool.py  
    local_sampling.py  
    selection_maximin.py  
    reporting.py  
    plots.py  
  outputs/{figures, tables, logs}
```

6.4 D. Snippets Python (les briques clés)

1) Estimer Σ + whitening

```
import numpy as np  
  
def cholesky_whitening(Sigma):  
    L = np.linalg.cholesky(Sigma)  
    Linv = np.linalg.inv(L)  
    return L, Linv  
  
def maha2(Sigma_inv, s):  
    s = np.asarray(s).reshape(-1,1)  
    return float((s.T @ Sigma_inv @ s)[0,0])
```

2) Lissage : sigmoid / softplus

```
import numpy as np  
  
def sigmoid(z):  
    return 1/(1+np.exp(-z))  
  
def softplus(u):  
    return np.log1p(np.exp(u))
```

```
# Ex: impose  $g \geq 0$  via  $g = \text{softplus}(u)$ 
```

3) PD logit (exposition par secteur)

```
import numpy as np

def pd_logit(PD0, beta_k, delta_k, g, x):
    # logit(PD) = logit(PD0) + beta'x + delta*g
    eps = 1e-12
    PD0 = np.clip(PD0, eps, 1-eps)
    logit0 = np.log(PD0/(1-PD0))
    z = logit0 + beta_k @ x + delta_k*g
    PD = 1/(1+np.exp(-z))
    return np.clip(PD, eps, 1-eps)
```

4) LGD affine + saturation lisse (recommandé)

```
import numpy as np

def lgd_affine_smooth(LGD0, gamma_k, eta_k, g, x):
    # smooth map to (0,1) via sigmoid around baseline
    eps = 1e-12
    LGD0 = np.clip(LGD0, eps, 1-eps)
    a0 = np.log(LGD0/(1-LGD0)) # logit(LGD0)
    z = a0 + gamma_k @ x + eta_k*g
    LGD = 1/(1+np.exp(-z))
    return np.clip(LGD, eps, 1-eps)
```

5) ASRF quantile loss L_q (équation 16)

```
import numpy as np
from scipy.stats import norm

def Lq_asrf(EAD, PD, LGD, rho, q=0.999):
    zq = norm.ppf(q)
    arg = (norm.ppf(PD) + np.sqrt(rho)*zq)/np.sqrt(1-rho)
    return np.sum(EAD * LGD * norm.cdf(arg))
```

6) RWA (approx linéaire eq. 21) + ratio R(s)

```
import numpy as np

def RWA_linear(RWA0, alpha, PD, PD0):
    return RWA0 + np.sum(alpha*(PD - PD0))

def CET1_stress(CET10, Lq, pnl_noncredit=0.0):
    return CET10 - Lq + pnl_noncredit

def R_ratio(CET1, RWA):
    return CET1 / max(RWA, 1e-12)
```

7) Réduction maximin (farthest point rule eq. 49)

```
import numpy as np

def farthest_point_selection(Y, P, start_idx=0):
    selected = [start_idx]
    dmin = np.linalg.norm(Y - Y[start_idx], axis=1)
    for _ in range(1, P):
        j = int(np.argmax(dmin))
        selected.append(j)
        dnew = np.linalg.norm(Y - Y[j], axis=1)
        dmin = np.minimum(dmin, dnew)
    return selected
```

7 Plan d'expérience / validation (pour “20/20”)

7.1 1) Tests data & plausibilité

- Σ SPD (valeurs propres > 0) ; condition number documenté.
- Forward simulation : tirer $S \sim \mathcal{N}(0, \Sigma)$, calculer $R(s)$; viser breach-rate 1–10% (sinon calibrer un facteur d'échelle global).
- Vérifier PD, LGD $\in (0, 1)$; monotonie si imposée.

7.2 2) Diagnostics optimisation

- Faisabilité : $|R(s) - R^l|$ petit (contrainte saturée).
- Plausibilité : $d_{\Sigma}^2(s)$ et score queue $\pi(s)$ reportés.
- Multi-start : diversité des optima locaux ; déduplication en y -space.

7.3 3) Gouvernance multi-scénarios


- Construire S_{η} (sensibilité locale) et/ou N_{ε} (alternatives lointaines).
- Produire $\mathcal{C}_P$ (5–12 scénarios) diversifiés via maximin.
- Pour chaque scénario : sévérité, plausibilité, drivers y ; + interprétation sectorielle $(PD_k^{\text{LGD}})_k$.

7.4 4) Backtesting narratif


Convertir g en échelle historique (quantile/z-score) et le comparer à des épisodes géopolitiques ; discuter “dans l'historique” vs “au-delà”.

8 Schémas (TikZ) : compréhension visuelle

8.1 Figure conceptuelle : ellipses de plausibilité et frontière de rupture



8.2 Roadmap 4 étapes



A Annexe A.1 : Référence Student multivariée (heavy tails) – du papier

Le papier propose une alternative heavy-tail à la gaussienne. **Important** : les ensembles admissibles (rupture et contraintes) ne changent pas ; seule la mesure de plausibilité change.

On suppose :

$$s \sim t_\nu(0, \Sigma). \quad (50)$$

Densité :

$$p_\nu(s) = c_{\nu,d} |\Sigma|^{-1/2} \left(1 + \frac{1}{\nu} d_\Sigma^2(s)\right)^{-(\nu+d)/2}, \quad d_\Sigma^2(s) = s^\top \Sigma^{-1} s. \quad (51)$$

La pénalité de plausibilité (négative log-densité, à constante près) :

$$\Psi_\nu(s) = \frac{\nu+d}{2} \log \left(1 + \frac{1}{\nu} d_\Sigma^2(s)\right). \quad (52)$$

Le design point Student s'obtient par :

$$\min_{s \in S_{\text{red}}} \Psi_\nu(s). \quad (53)$$

Comme $u \mapsto \log(1 + u/\nu)$ est croissante, minimiser $\Psi_\nu(s)$ revient à minimiser $d_\Sigma^2(s)$: **l'optimum (argmin) est le même** si Σ est fixe, mais la **calibration probabiliste** (p-value) change : sous Student, les queues sont plus épaisses, donc des scénarios extrêmes peuvent être plus plausibles.

B Annexe A.2 : Version sectorielle (équations 56–62 du papier) + explication

Quand on n’a pas (ou peu) de données par exposition, on travaille par secteurs $k = 1, \dots, K$.

Poids d’exposition sectoriels

$$w_k := \frac{\text{EAD}_k}{\sum_{j=1}^K \text{EAD}_j}. \quad (56)$$

PD sectorielle (logit)

$$\text{logit}(\text{PD}_k(g, x)) = \text{logit}(\text{PD}_k^0) + \mathbf{b}_k^\top x + d_k g. \quad (57)$$

d_k mesure la sensibilité géopolitique du secteur k .

LGD sectorielle (affine)

$$\text{LGD}_k(g, x) = \text{LGD}_k^0 + \mathbf{c}_k^\top x + e_k g. \quad (58)$$

e_k mesure la sensibilité géopolitique de la sévérité de perte (recouvrement/collatéral).

Quantile de pertes sectoriel

$$L_q(g, x) \approx \sum_{k=1}^K \text{EAD}_k \text{LGD}_k(g, x) \Phi \left(\frac{\Phi^{-1}(\text{PD}_k(g, x)) + \sqrt{\rho_k} \Phi^{-1}(q)}{\sqrt{1 - \rho_k}} \right). \quad (59)$$

RWA sectorielle

$$\text{RWA}(g, x) = \sum_{k=1}^K \text{EAD}_k \text{RW}_k(g, x). \quad (60)$$

Poids de risque :

$$\text{RW}_k(g, x) = \text{LGD}_k(g, x) \left[\Phi \left(\frac{\Phi^{-1}(\text{PD}_k(g, x)) + \sqrt{\rho_k} \Phi^{-1}(q)}{\sqrt{1 - \rho_k}} \right) - \text{PD}_k(g, x) \right]. \quad (61)$$

Approximation linéaire :

$$\text{RW}_k(g, x) = \omega_k + \varepsilon_k^{RW} (\text{PD}_k(g, x) - \text{PD}_k^0). \quad (62)$$

Ensuite, le reverse stress est inchangé : minimiser $\frac{1}{2} d_\Sigma^2(s)$ sous $R(s) \leq R$, mais $R(s)$ est calculé avec (57)–(62).

C Références (sélection minimale, à compléter si besoin)

Références

- [1] Gordy, M. (2003). A risk-factor model foundation for ratings-based bank capital rules.
- [2] Vasicek, O. (2002). The distribution of loan portfolio value. *Risk*.
- [3] Boyd, S. and Vandenberghe, L. (2004). *Convex Optimization*.

- [4] Caldara, D. and Iacoviello, M. (2022). Measuring geopolitical risk. *AER*.
- [5] BCBS (2009). Principles for sound stress testing practices and supervision.
- [6] BCBS (2023). IRB approach : Risk weight functions.
- [7] Glasserman et al. (2015). Stress scenario selection by empirical likelihood.
- [8] Pesenti et al. (2019). Divergence-based reverse stress testing.